# BROT Neo4j

November 8, 2022

## 1 Projet Neo4j sur la base de données BROT

Yannis BARBA

#### 1.0.1 Contexte

Pour ce projet visant à travailler avec une base de données sous forme de graphe avec neo4j, j'ai souhaité mettre à profit cette technologie dans le domaine de l'écologie (étude des populations et des écosystèmes).

Au cours de mes recherches, j'ai découvert une base de données recensant un grand nombre d'espèce méditérranénnes ainsi que leur traits. Les traits étant des charactéristiques phénotypiques, génétiques ou morphologiques d'un organisme (ref). Les auteurs de cette base de données sont Çağatay Tavşanoğlu & Juli G. Pausas. Ils ont référencé 2457 taxons méditérranéens et un total de 44 traits, pour obtenir au final 25 764 individus, un individu étant la mesure d'un trait pour un taxon donné (tous les traits ne sont pas recensés pour chaque taxons).

Cette base de données a été constituée de plusieurs manières notamment grâce à des références bibliographiques et des observations expérimentales. Ainsi, pour chaque paire taxon-trait observé, donc pour chaque ligne, il y a également une source bibliographique.

La base de données est composée en 4 fichiers csv:

- BROT2 dat.csv (toutes les paires taxon-trait observé)
- BROT2\_sou.csv (toutes les sources)
- BROT2 tax.csv (toutes les informations supplémentaires sur les taxons)
- BROT2 syn.csv (tous les synonymes des taxons)

J'ai également décidé de créer un fichier **traits.csv**, permettant d'avoir le nom complet d'un trait et des explications le concernant. Ces informations sont disponibles dans l'article sur lequel j'ai basé mon projet (ref). J'ai décidé de créer ce fichier afin d'avoir l'information directement dans le résultat de mes requêtes et ne pas avoir à me référer systématiquement à l'article pour analyser mes résultats.

#### 1.1 Problématique

A partir de ce jeu de données, les problématiques possibles sont très nombreuses. D'après l'article ce type de base de données (sur les traits) est très prometteur pour les biologistes afin de comprendre la répartition de populations et la formation d'écosystèmes.

Une base de donnée sous forme de graphe semble tout à fait adaptée, puisqu'elle permet de visualiser assez aisément les appartenances des taxons aux différentes familles, les taxons possédant tel ou

tel trait etc. Par ailleurs au cours de mes recherhces, j'ai pu constater que les bases de données de traits étaient souvent sous forme de graphe.

Les sujets de réflexions étant vastes, j'ai décidé de me concentrer sur certaines questions que je me suis posé au premier abord en lisant l'article.

Dans un premier temps, comme l'auteur a identifié des traits en lien avec la résillience des plantes au incendie, j'ai décidé de me concentrer sur l'étude de ces traits. En effet, la présence du feu en méditérranée a eu un impact sur le développement des populations y compris végétales. Certaines espèces ont développé des traits traduisant une adaptation à cette pression environnementale particulière.

Je me suis donc demandé si l'on pouvait identifier un pattern de plantes adpatées à la présence du feu en méditérranée. Comme nous allons le voir par la suite, certains traits sont des mesures directes de l'adaptation aux incendies. Mais je voulais savoir si parmis les plantes qui possèdent ces traits, nous pouvions mettre en évidence d'autres traits qui ne serait pas directement associés à l'adaptation au feu.

```
Connexion à la base de données
```

```
[80]: from py2neo import *
  import pandas as pd
  from pandas import DataFrame
  import matplotlib.pyplot as plt
  graph = Graph("bolt://localhost:7687", auth=("neo4j", "root"))
```

## 1.2 Adaptation aux incendies

Afin de répondre à la première probématique posée, il nous faut définir ce que sont les taxons présentants des adaptations aux incendies. A partir de la description des traits dans l'article, j'ai pu définir un ensemble de trait définissant une adaptation aux incendies, la modalité choisie est indiquée en ().

- Fire-stimulated flowering **FireStimFlower** (yes)
- Resprouting capacity after fire **RespFire** (high)
- Chemical germination cues **ChemCues** (stimulation)
- Heat-stimulated germination **HeatStimGerm** (high|LMH)
- Post-fire seedling emergence **SeedlEmerg** (high)
- Post-fire seedling survival **SeedlSurv** (high)

Afin de connaître la description de chacun des traits choisis, nous pouvons interoger la base de données avec une première requête simple.

```
print(f"Trait : {res['name'][0]} \n {res['explanation'][0]} \n \n")
```

#### #######################

Trait : FireStimFlower

Fire-stimulated <code>i¬</code> owering in post-<code>i¬</code> re resprouters.

#### ##########################

Trait : RespFire

Resprouting capacity after one year when most of the plant has been scorched (average proportion of

adult plants that resprout as percentage). Not reported for annual plants (which can be assumed to be RespFire = no).

#### ########################

Trait : ChemCues

Germinative response to smoke (smk), ash (ash), charcoal (cha), nitrogenous compounds like KNO 3

(NC1), NaNO 2 (NC2), NH 4 Cl (NC3), NH 4 HOC 3 (NC4), NH 4 NO 3 (NC5), or response to karrikins

(KAR), cyanohydrins (CYN, including several cyanides, mandelonitrile, and glyceronitrile). The response

in indicated before the vertical bar, and the chemical cue tested, after the vertical bar (e.g. stimulation  $\mid$  Smk).

#### ########################

Trait : HeatStimGerm

The highest intensity in heat treatments (i.e., seed exposition to dry heat > =  $50 \text{ } \hat{A}^{\circ}\text{C}$ ) that produce higher

germination than the control (i.e., stimulated germination). Heat intensity deïned as: Low (L: o100  ${\rm \hat{A}}$  °C

during o = 5 min.), Moderate (M:o100  $\hat{A}$ °C during >5 min. or > = 100  $\hat{A}$ °C during o = 5 min.), High

(H: > = 100  $\hat{A}$  °C during >5 min.) or unknown (unk). Note that in many cases, post-treatment seed viability

is not considered or not specii¬ed. The heat intensities tested for each experiment are indicated after

the vertical bar (category  $\mid LMH \rangle$  , with an underscore when the corresponding heat intensity is not tested

(e.g., category|L\_H).

#### #######################

```
Trait: SeedlEmerg

Average density of seedlings per pre-ï¬re mature individuals emerged during the ï¬rst year after ï¬re. This is a ratio (number of seedlings / number of mature plants)
```

#### #######################

Trait : SeedlSurv

Proportion of seedlings surviving the <code>i¬rst</code> dry season after <code>i¬re</code> (%).

Pour des fonctions réutilisées régulièrement, j'ai décidé de créer un fichier db\_request

Nombre de taxons : 2457 Nombre famille : 119

## 1.2.1 Identification des familles dont certaines espèces sont adaptées aux incendies

Regardons dans un premier temps tous les taxons ayant au moins une modalité d'un des traits identifié précédemment. C'est à dire les taxons présentant au moins une adaptation au feu.

la modalité stimulation/smk pour le trait **ChemCues**, signifie que le taxon voit sa germination stimulée par la fumée.

```
[33]: fireTraits = {
    "FireStimFlower": "yes",
    "RespFire": "high",
    "ChemCues" : "stimulation|smk",
    "HeatStimGerm" : "high|LMH",
    "SeedlEmerg" : "high",
    "SeedlSurv" : "high"
}
```

```
def allTaxonAdaptedTo(fireTraits):
    rg = ""
    maxUnion = 0
    for key, value in fireTraits.items():
        rq += f"match(tx:Taxon)<-[:TRAIT_OF_TAXON]-(d:Data {{data:__
 →'{value}'}})-[:TYPE_OF_TRAIT]->(t:Trait {{name: '{key}'}}) return tx.taxonu
 ⇔as taxon, t.name as trait, d.data as data"
        if(maxUnion < len(fireTraits)-1):</pre>
            rq += " UNION "
            maxUnion+=1
    return graph.run(rq).to_data_frame()
allTaxonAdaptedToFire = allTaxonAdaptedTo(fireTraits)
print(allTaxonAdaptedToFire)
print(f"{allTaxonAdaptedToFire.shape[0]} taxons présentent au moins une⊔
 ⇒adaptation au feu")
print(f"soit {round((allTaxonAdaptedToFire.shape[0]/len(allTaxons))*100, 2)}%_L

des taxons")
```

```
taxon
                                     trait data
0
        Asphodelus ramosus FireStimFlower
                                             yes
1
     Cyclamen hederifolium FireStimFlower
                                             yes
2
        Muscari racemosum FireStimFlower
                                             yes
3
          Urginea maritima FireStimFlower
                                             yes
4
      Narcissus triandrus FireStimFlower
                                             yes
. .
382
      Euphorbia characias
                                 SeedlSurv high
383
      Genista acanthoclada
                                 SeedlSurv high
384
           Fumana laevipes
                                 SeedlSurv high
385
        Micromeria juliana
                                 SeedlSurv high
386
      Trifolium campestre
                                 SeedlSurv high
[387 rows x 3 columns]
387 taxons présentent au moins une adaptation au feu
soit 15.75% des taxons
```

N'ayant pas de connaissance préalable sur le sujet (les adaptations des plantes au feu), j'ai décidé d'aborder dans un premier temps une approche dite "naïve", c'est à dire que j'étudie dans un premier temps les différents trait identifés précédemment.

Focus sur tous les traits lié aux incendies Nous pouvons maintenant regarder pour l'ensemble des traits identifiés comme étant une adadaptation au feu, lequel est le plus représenté.

```
[34]: for trait, modality in fireTraits.items():
    taxonWithTraitAndMod = allTaxonWithTraitAndModality(trait, modality)
    nbreTaxon = len(taxonWithTraitAndMod)
    perc = round((nbreTaxon/allTaxonAdaptedToFire.shape[0])*100, 2)
```

```
print("########") print(f"{perc}% des taxons présentant une adaptation au feu ont la modalité \cup {modality} pour le trait {trait}")
```

#### ##########

6.2% des taxons présentant une adaptation au feu ont la modalité yes pour le trait FireStimFlower

#### ###########

30.75% des taxons présentant une adaptation au feu ont la modalité high pour le trait RespFire

#### ##########

22.22% des taxons présentant une adaptation au feu ont la modalité stimulation|smk pour le trait ChemCues

#### ###########

15.5% des taxons présentant une adaptation au feu ont la modalité high|LMH pour le trait HeatStimGerm

#### ###########

47.29% des taxons présentant une adaptation au feu ont la modalité high pour le trait SeedlEmerg

#### ###########

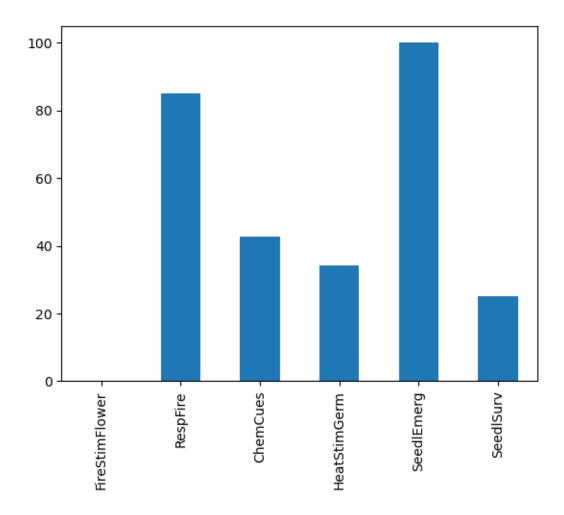
10.59% des taxons présentant une adaptation au feu ont la modalité high pour le trait SeedlSurv

Focus sur le trait SeedEmerg C'est le trait SeedEmerg qui est le trait le plus représenté parmi les taxons possédant au moins un trait d'adaptation au feu. C'est pourquoi j'ai décidé de me concentrer d'abord sur ce trait.

Dans un premier temps, déterminons si les taxons possédant ce trait possédent également d'autres traits d'adaptation au feu.

```
[35]: colname = [key for key, value in fireTraits.items()]
seedEmergTaxon = allTaxonWithTraitAndModality("SeedlEmerg", "high")
seedEmergTaxonWithTraits = pd.DataFrame(columns=colname)
def ContingenceMatrixToCompare(baseTrait, baseModality, traitsAndModality):
    """Cette fonction retourne une matrice de contingence permettant de_u
    déterminer si des taxons possédant
    un trait et une modalité donnée possède d'autres traits et modalités"""
    colname = [key for key, value in traitsAndModality.items()]
    taxonFromBaseTrait = allTaxonWithTraitAndModality(baseTrait, baseModality)
    matrix = pd.DataFrame(columns=colname)
for tax in taxonFromBaseTrait["taxon"]:
```

```
mod = {key:0 for key,value in traitsAndModality.items()}
              rq = '''match(tx:Taxon {taxon: $tax})<-[:TRAIT_OF_TAXON]-(d:Data)-[:</pre>
       →TYPE_OF_TRAIT]->(t:Trait) return t.name as trait, d.data as modality'''
              allTraits = graph.run(rq, tax=tax).to_data_frame()
              for trait in colname:
                  if allTraits["trait"].isin([trait]).any():
                      if allTraits["modality"][allTraits["trait"][allTraits["trait"]_
       \Rightarrow == trait].index[0]]:
                          mod[trait] = 1
              matrix.loc[tax] = [value for key, value in mod.items()]
          return matrix
      seedlEmergContingenceMatrix = ContingenceMatrixToCompare("SeedlEmerg", "high", ___
       ⊶fireTraits)
[47]: | seedlEmergRatio = round((seedlEmergContingenceMatrix.sum(axis="rows")/
       ⇒seedlEmergContingenceMatrix.shape[0])*100,2)
      print(type(seedlEmergRatio))
      seedlEmergRatio.plot(kind="bar")
     <class 'pandas.core.series.Series'>
[47]: <AxesSubplot:>
```



D'après le graphe ci-dessus, nous pouvons dire que les taxons possédant le trait  $\mathbf{SeedlEmerg}$  et la modalité high, c'est à dire une forte densité d'individu mature un an après un incendie:

- 85% d'entre eux ont la modalité "high" pour le trait **RespFire** qui correspond à la capacité de repousse 1 an après un incendie. Cela semble cohérent, car s'il y a une forte densité de population, c'est bien que les individus ont une forte capacité à la repousse. Cette forte corrélation est donc logique.
- 42% d'entre eux ont la modalité "stimulation/smk" pour le trait **ChemCues**, ce qui veut dire que leur germination est stimulée par le feu, ce qui encore une fois est plutôt logique, mais nous pourrions également regarder quelles sont les modalités pour ce trait afin d'apporter plus de finesse dans l'analyse.
- 34 % d'entre eux ont la modalité "high/LMH", pour le trait **HeatStimGerm** c'est à dire que la germination est stimulée lors d'une chaleur très importante, c'est à dire supérieure à 100°C pendant plus de 5min. (Attention, dans le cadre de ce projet, j'ai choisi de me concentrer sur une seule modalité par soucis de simplification pour ce trait, mais comme nous pouvons le constater, les modalités sont plus nombreuses, les résultats sont donc à prendre avec des pincettes).

- 25% ont la modalité "high" pour le trait **SeedlSurv**, trait qui correspond à la proportion de graines ayant survécus la première saison sèche après l'incendie.
- 0 % d'entre eux n'ont la modalité "yes" pour le trait **FireStimFlower**, soit ce trait n'a pas été renseigné pour ces espèces, soit, un taxon à une adaptation au feu au niveau de la germination OU au niveau de la floraison mais pas pour les deux en même temps.

Il me semble maintenant intéressant de regarder pour tous les taxons possédant le trait **SeedlE-merg** et la modalité *high*, quels sont les traits et leur modalités les plus représentés, afin de comprendre s'il y a des liens entre les traits d'adaptation au feu et les autres.

```
[59]: def allTraitsOfTaxons(taxons):
          """Pour une liste de taxons donné, cette fonction retourne un dictionnaire_{\sqcup}
       ⇔avec l'ensemble des traits observés
          et le nombre de fois que ces trais ont été observé pour tous ces taxons∟
       ⇒ainsi que le nombre de fois où chacune
          des modalités a été observé"""
          traits = {}
          for tax in taxons:
              rq = '''match(tx:Taxon {taxon: $tax})<-[:TRAIT_OF_TAXON]-(d:Data)-[:
       GTYPE_OF_TRAIT] ->(t:Trait) return t.name as trait, d.data as modality'''
              allTraits = graph.run(rq, tax=tax).to_data_frame()
              for trait in allTraits["trait"].unique():
                  modality =
       allTraits["modality"] [allTraits["trait"] [allTraits["trait"] == trait].
       →index[0]]
                  if trait in traits:
                      traits[trait]["somme"] +=1
                      if modality in traits[trait]:
                          traits[trait] [modality] = traits[trait] [modality] + 1
                      else :
                          traits[trait].update({modality: 1})
                  else :
                      traits.update({trait: {"somme": 1, modality: 1}})
          return traits
      #test = allTraitsOfTaxons(["Ononis pusilla"])
      allTraitsForAllTaxonWithSeedlEmerg = allTraitsOfTaxons(seedEmergTaxon["taxon"])
[67]: seedlEmergContingenceMatrix.shape
[67]: (140, 6)
[68]: traitsOccurences = pd.Series({key:__
       →(allTraitsForAllTaxonWithSeedlEmerg[key]["somme"]/
       -allTraitsForAllTaxonWithSeedlEmerg["SeedlEmerg"]["somme"])*100 for key,
       ⇒value in allTraitsForAllTaxonWithSeedlEmerg.items()})
```

## print(len(traitsOccurences))

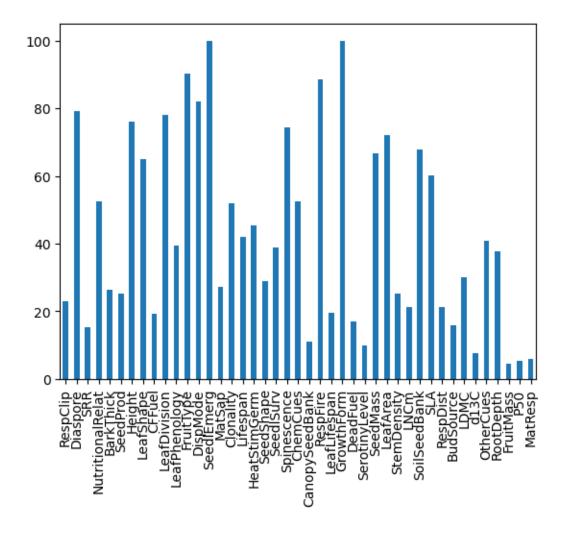
43

Nous obtenons au total 43 traits sur 44, c'est à dire que la quasi-totalité des traits sont étudiés pour l'ensemble des taxons possédant le trait **SeedlEmerg** et la modalité *high* 

Regardons maintenant quels sont les traits les plus représentés parmis l'ensemble des taxons. Attention, si un trait n'apparaît pas pour un taxon donné, cela ne veut pas dire que celui-ci ne le possède pas dans l'absolu, cela signifie simplement que la littérature n'a pas donné d'information à ce sujet. Le graphe ci-dessous nous permet simplement d'extraitre les traits qui sont les plus intéressants à étudier, puisque présent pour la majeure partie des taxons possédant le trait **SeedEmerg** et la modalité *high* 

[69]: traitsOccurences.plot(kind="bar")

## [69]: <AxesSubplot:>




Tout à fait arbitrairement, j'ai décidé de m'intéresser aux traits dont on à l'information pour 80% des taxons possédant déjà le trait **SeedEmerg** et la modalité *high*. Je retiens donc les traits :


- Diaspore
- FruitType
- DispMode
- RespFire
- GrowthForm


Bien entendu, dans une étude plus approfondie et avec de meilleure connaissance du domaine, d'autres choix de traits d'études pourraient être fait.


Avec la fonction *allTraitsOfTaxons* j'ai les modalités pour chacun des traits ainsi que le nombre de fois où ces modalités ont été prises.


```
[78]: traitsOfInterest = ["Diaspore", "FruitType", "DispMode", "RespFire", "
      ⇔"GrowthForm"]
      for trait in traitsOfInterest:
          print(f"{trait} : {allTraitsForAllTaxonWithSeedlEmerg[trait]} \n")
     Diaspore : {'seed': 112, 'fruit': 33}
     FruitType : {'dry': 161, 'fleshy': 4}
     DispMode: {'WG': 23, 'WM': 1, 'MBG': 3, 'G': 34, 'WZG': 3, 'ZG': 4, 'P': 3,
     'BG': 4, 'WPG': 3, 'B': 6, 'Z': 2, 'NWGP': 2, 'GM': 3, 'WNG': 1, 'NG': 8, 'W':
     18, 'GB': 7, 'M': 2, 'WZ': 9, 'NPG': 3, 'PH': 1, 'PMG': 3, 'PMBG': 2, 'MG': 1,
     'WP': 2, 'HG': 1, 'GW': 1}
     RespFire: {'no': 127, 'yes': 29, 'low': 3, 'high': 1, 'variable': 1, '0': 1}
     GrowthForm: {'tree': 20, 'subshrub': 22, 'perennial forb': 11, 'shrub': 32,
     'annual forb': 82, 'annual graminoid': 6, 'variable forb': 7, 'perennial
     graminoid': 2, 'geophyte': 1}
[81]: for trait in traitsOfInterest:
          copy = allTraitsForAllTaxonWithSeedlEmerg[trait]
          if "somme" in copy:
              del copy["somme"]
          pd.Series(copy).plot(kind="bar")
          plt.show()
```











## Focus sur le trait FireStimFlower

```
Nombre de plante possédant ce trait : 24

Nombre de familles ayant au moins une espèce dont la floraison est stimulée pour les incendies : 8

['Asphodelaceae' 'Primulaceae' 'Asparagaceae' 'Amaryllidaceae' 'Liliaceae' 'Dioscoreaceae' 'Araceae' 'Iridaceae']
```

6.72% des familles possèdent au moins une espèce ayant le trait FireStimFlower 0.98% des taxons ont une floraison stimulée par le feu 7.48% des taxons ayant au moins une adapatation au feu ont une floraison stimulée par le feu

Seulement 6% des familles possédent au moins une espèce ayant le trait **FireStimFlower**. Et moins d'1% des plantes voient leur floraison stimulée par le feu.

D'après la documentation, ce trait indique que les plantes le possédant sont capables (voire nécessitent) de fleurir après des incendies. Si l'on regarde un peu plus en détail la documentation, il est indiqué que ce sont les plantes géophytes qui présentent le plus ce trait. Une plante géophyte est une plante qui possède un organe permettant de "passer la mauvaise saison" (wikipédia), tel qu'un bulbe ou bien un rhizome. On peut donc regarder la proportion de plantes géophytes dans celle présentant le trait **FireStimFlower**.

Il existe un trait : GrowthForm renseignant les plantes géophytes ou non.

```
[14]: for el in fireStimFlower["taxon"]:
    print(el, modalityOfOneTraitForOneTaxon(el, "GrowthForm"))
```

```
Asphodelus ramosus ['geophyte']
Cyclamen hederifolium ['geophyte']
Muscari racemosum ['geophyte']
Urginea maritima ['geophyte']
Narcissus triandrus ['geophyte']
Narcissus dubius ['geophyte']
Gagea peduncularis ['geophyte']
Dioscorea communis ['geophyte']
Acis nicaeensis ['geophyte']
Ornithogalum narbonense ['geophyte']
Arisarum vulgare ['geophyte']
Gladiolus illyricus ['geophyte']
Iris lutescens ['geophyte']
Lapiedra martinezii ['geophyte']
Gladiolus illyricus ['geophyte']
Romulea tempskyana ['geophyte']
Ornithogalum sphaerocarpum ['geophyte']
Allium hirtovaginatum ['geophyte']
Allium sandrasicum ['geophyte']
Allium amethystinum ['geophyte']
Gagea graeca ['geophyte']
Leopoldia comosa ['geophyte']
Asparagus stipularis ['liana']
Allium stamineum ['geophyte']
```

Nous pouvons constater qu'a l'exception du taxon "Asparagus stipularis", tous les taxons avec le trait **FireStimFlower** sont en fait des géophytes.

Nous pouvons regarder combien de plantes sont géophytes dans notre base de données avec de savoir si le fait d'être géophyte suffit pour voir sa floraison stimulé par le feu ou bien s'il faut prendre en compte d'autre caractéres.

```
[15]: allGeophytes = allTaxonWithTraitAndModality("GrowthForm", "geophyte")
print(f"{round((len(fireStimFlower) / len(allGeophytes))*100)} % des geophytes_
possédent le trait FireStimFlower")
```

### 13 % des geophytes possédent le trait FireStimFlower

D'après le résultat précédent, nous pouvons constater que le fait d'être géophyte n'est pas suffisant pour avoir une floraison stimulée par le feu.

Ce trait ne semble pas être discriminant